



Hochschule für angewandte Wissenschaften Coburg
Fakultät Elektrotechnik und Informatik

Studiengang: Informatik

Bachelorarbeit

Multi-Modal Feature Fusion with Cross-Attention for Tabular and Textual Data

Städler, Sebastian

Abgabe der Arbeit: 27.01.2026

Betreut durch:

Prof. Dr. Roman Rischke, Hochschule Coburg

Abstract

TODO ...

Inhaltsverzeichnis

Abstract	I
Abbildungsverzeichnis	IV
Tabellenverzeichnis	V
Abkürzungsverzeichnis	VI
1 Einführung	1
1.1 Problemstellung und Motivation	1
1.2 Zielsetzung und Forschungsfragen	2
1.3 Beitrag und Aufbau der Arbeit	2
1.4 Voraussetzungen an den Lesenden	3
2 Theoretische Grundlagen	4
2.1 Multimodale Daten	4
2.1.1 Heterogenität in multimodalen Daten	4
2.1.2 Repräsentation von Textdaten	4
2.1.3 Repräsentation tabellarischer Daten	6
2.2 Transformer-Architekturen und Attention-Mechanismen	8
2.2.1 Der Transformer-Encoder	8
2.2.2 Scaled Dot-Product Attention	9
2.2.3 Self-Attention vs. Cross-Attention	9
2.3 Strategien der multimodalen Fusion	10
2.3.1 Mechanismen der Fusion	10
2.3.2 Architekturen und Positionierung der Fusion	11
3 Verwandte Arbeiten	13
3.1 Cross-Attention in multimodalen Transformer-Architekturen	13
3.2 Verarbeitung von Tabellen und Text mit Transformern	13
3.3 Forschungslücke und Einordnung	15
4 Methodik	16
4.1 Datenbasis und Vorverarbeitung	16
4.2 Baseline-Modelle	18
4.2.1 SumBERT (Early Fusion)	18
4.2.2 ConcatBERT (Late Fusion)	19
4.3 CrossBERT-Architektur	20
4.3.1 Architekturüberblick	20

4.3.2	TabularTokenizer	20
4.3.3	Cross-Attention-Block	21
4.3.4	Fusionsvarianten: Early, Late und Hybrid	23
4.4	Trainings-Setup und Evaluationsmetriken	23
4.5	Ablationsstudien	25
5	Ergebnisse	26
5.1	Hauptexperiment	26
5.2	Ablationsstudien	26
5.2.1	Einfluss der Cross-Attention-Positionierung	27
5.2.2	Einfluss der Anzahl der Tab Tokens	27
5.2.3	Tabular Tokenizer V2 und Gating	27
5.3	Externe Validierung	28
5.3.1	Petfinder-Datensatz	28
5.3.2	E-Commerce-Datensatz	28
5.4	Illustrative Explainability-Analyse	29
6	Diskussion und Fazit	31
6.1	Diskussion der Forschungsfragen	31
6.2	Fazit	33
	Literaturverzeichnis	VII
	A1 Anhang	XI
A1.1	Modellarchitektur CrossFitter	XI
A1.2	Evaluation auf dem Petfinder-Datensatz	XI
A1.3	Evaluation auf dem E-Commerce-Datensatz	XII
A1.4	Robustheitsprüfung mit anderem Random Seed	XII
A1.5	Ablationsstudie: Tabular Tokenizer V2	XIII
A1.6	Ablationsstudie: Gating-Mechanismus	XIII
A1.7	Ablationsstudie: Anzahl der Tabular Tokens	XIV
	Ehrenwörtliche Erklärung	XV

Abbildungsverzeichnis

Abb. 1:	Architektur von SumBERT: Addition der Tabellen-Repräsentation zum CLS-Token-Embedding vor dem Encoder. Quelle: [Fue24].	18
Abb. 2:	Architektur von ConcatBERT: Konkatenation der Tabellen-Features mit dem Output des BERT-Encoders. Quelle: [Fue24].	19
Abb. 3:	Architektur von CrossBERT mit optionaler Early- und Late-Cross-Attention über Tab Tokens.	21
Abb. 4:	Komponenten der CrossBERT-Architektur: Links die Projektion der Features in Tab Tokens, rechts deren Integration via Cross-Attention.	22
Abb. 5:	Vergleich der PR- und ROC-Kurven für CrossBERT Early, Late und Hybrid.	27
Abb. 6:	Good Case Analyse: Oben der SHAP-Waterfall-Plot, unten die Attention-Weights der Early- (links) und Late-Fusion (rechts).	30
Abb. 7:	Bad Case Analyse: Oben der SHAP-Waterfall-Plot, unten die Attention-Weights der Early- (links) und Late-Fusion (rechts).	30
Abb. 8:	Schematische Darstellung der CrossFitter-Modellarchitektur im produktiven Einsatz. Quelle: [Fue24].	XI
Abb. 9:	Konfusionsmatrizen der Modelle auf dem Petfinder-Testdatensatz. Die Titel zeigen den jeweiligen Test-QWK.	XII

Tabellenverzeichnis

Tab. 1:	Exemplarischer Datensatz der internen Regressdatenbasis (anonymisiert). . .	16
Tab. 2:	Zentrale Trainingshyperparameter (Basiskonfiguration ohne Gating).	24
Tab. 3:	Übersicht der geplanten Ablationsstudien	25
Tab. 4:	Vergleich der Hauptmetriken auf dem Testdatensatz (Seed 777). Hervorgeho- bene Werte markieren das beste Ergebnis pro Metrik.	26
Tab. 5:	Auszug der Petfinder-Ergebnisse (Test QWK). CrossBERT Hybrid zeigt hier eine deutliche Verbesserung gegenüber den Baselines.	28
Tab. 6:	Ergebnisse der Evaluation auf dem Petfinder-Datensatz (Metrik: Quadratic Weighted Kappa (QWK))	XI
Tab. 7:	Ergebnisse der Evaluation auf dem E-Commerce-Datensatz	XII
Tab. 8:	Ergebnisse der Robustheitsprüfung	XIII
Tab. 9:	Ergebnisse der Ablationsstudie zum Tabular Tokenizer V2. Die feature-spezifischen Projektionen bieten keinen Mehrwert gegenüber der einfacheren V1-Variante. XIII	
Tab. 10:	Ergebnisse der Ablationsstudie zum Gating-Mechanismus. Die Erweiterung zeigt einen leichten zusätzlichen Gewinn gegenüber der Basis-Hybrid-VarianteXIII	
Tab. 11:	Ergebnisse der Ablationsstudie zur Anzahl der Tabular Tokens (n_{tab}). Ab $n = 8$ zeigt sich eine Sättigung; bei $n = 16$ sinkt die AUC leicht, während die AP auf ähnlichem Niveau bleibt.	XIV

Abkürzungsverzeichnis

AP	Average Precision
AUC-ROC	Area Under the Receiver Operating Characteristic Curve
BERT	Bidirectional Encoder Representations from Transformers
ELMo	Embeddings from Language Models
FLOPs	Floating Point Operations
GBDT	Gradient Boosted Decision Tree
LGBM	Light Gradient Boosting Machine
MLP	Multi-Layer Perceptron
NLP	Natural Language Processing
OHE	One-Hot Encoding
QWK	Quadratic Weighted Kappa
SHAP	SHapley Additive exPlanations
TF-IDF	Term Frequency-Inverse Document Frequency

1 Einführung

Digitale Entscheidungsprozesse in der Versicherungswirtschaft stützen sich zunehmend auf heterogene Datenquellen. Neben klassischen, strukturierten Vertrags- und Schadendaten entstehen im Schadenbearbeitungsprozess umfangreiche Freitexte, wie Schadenhergangsbeschreibungen, Korrespondenz oder Notizen der Sachbearbeitenden. Für viele Fragestellungen genügt es nicht, diese Quellen isoliert zu betrachten. Erst die gemeinsame Auswertung von strukturierten Merkmalen und natürlichsprachlichen Informationen erlaubt eine präzise Einschätzung komplexer Sachverhalte.

Ein zentrales Anwendungsfeld ist die Identifikation von Regresspotenzialen. Nach der Regulierung eines Schadens prüft das Versicherungsunternehmen, ob Ansprüche gegenüber Dritten (z. B. Verursachern oder anderen Versicherern) geltend gemacht werden können. In der Praxis wird oft nur ein Teil der Fälle einer vertieften Prüfung unterzogen, basierend auf Erfahrungswissen oder einfachen Regeln. Dies birgt das Risiko, dass Regressansprüche unentdeckt bleiben.

1.1 Problemstellung und Motivation

Die Herausforderung besteht darin, das Regresspotenzial einzelner Schadenfälle automatisiert vorherzusagen, um die manuelle Prüfung effizienter zu steuern. Hierfür stehen sowohl tabellarische Daten als auch Freitexte zur Verfügung. Die zentrale Problemstellung ist die effektive Fusion dieser Modalitäten. Etablierte Verfahren im Unternehmenskontext nutzen oft nur einfache Fusionsstrategien wie Konkatenation oder Addition, wodurch das Potenzial einer tiefergehenden Interaktion zwischen den Datenarten ungenutzt bleibt.

Neuere Ansätze aus dem Bereich der multimodalen Transformer, insbesondere die Cross-Attention, ermöglichen einen gezielten Informationsaustausch zwischen verschiedenen Modalitäten. Für die spezifische Kombination von Tabellen- und Textdaten im Versicherungskontext ist jedoch noch unzureichend erforscht, ob und wann komplexe Mechanismen wie Cross-Attention gegenüber einfacheren, ressourcensparenden Methoden einen tatsächlichen Mehrwert bieten.

Der in dieser Arbeit betrachtete Anwendungsfall basiert auf realen Daten eines großen deutschen Versicherungsunternehmens. Dies impliziert Herausforderungen wie unvollständige Daten und historisch bedingte Verzerrungen (Selection Bias), da das Modell auf Basis vergangener, menschlicher Entscheidungen trainiert wird. Dabei ist festzuhalten, dass die Problematik des Selection Bias ein Grundproblem des primären Datensatzes darstellt und nicht Untersuchungsgegenstand dieser Arbeit ist. Ziel der Arbeit ist ein robustes Modell, das die Priorisierung von zu prüfenden Fällen unterstützt und so zur Wirtschaftlichkeit der Schadenbearbeitung beiträgt.

1.2 Zielsetzung und Forschungsfragen

Ziel dieser Arbeit ist die Entwicklung und Evaluation einer multimodalen Transformer-Architektur („CrossBERT“), die Text- und Tabellendaten mittels Cross-Attention verknüpft. Im Vergleich zu Baselines mit statischer Fusion (SumBERT, ConcatBERT) soll untersucht werden, inwiefern die dynamische Gewichtung der Informationen die Vorhersagegüte verbessert.

Daraus leiten sich folgende Forschungsfragen ab:

1. Welche Unterschiede in der Vorhersagequalität zeigen sich zwischen Cross-Attention-Modellen und einfachen Baselines wie einfacher Konkatination oder Addition bei der Fusion von Text- und Tabulardaten?
2. Welchen Einfluss hat die Positionierung des Cross-Attention-Blocks (Early, Late oder Hybrid) auf die Modellleistung?
3. Welche Stärken und Schwächen ergeben sich aus der Evaluation dieser Ansätze und welche Schlüsse lassen sich für die Weiterentwicklung multimodaler Modelle ziehen?

1.3 Beitrag und Aufbau der Arbeit

Die Arbeit leistet einen Beitrag zur angewandten Forschung im Bereich multimodaler Deep-Learning-Modelle für Tabular-Text-Daten. Kernpunkte sind:

- **Modellentwicklung:** Konzeption der CrossBERT-Architektur zur Integration heterogener Datenströme.
- **Evaluation:** Systematischer Vergleich mit etablierten Baselines auf einem internen Versicherungsdatensatz sowie externen Benchmarks, unter Berücksichtigung von Performance und Effizienz.
- **Analyse:** Untersuchung verschiedener Fusionsarchitekturen und deren Auswirkung auf die Modellentscheidung.

Der Aufbau der Arbeit folgt dem Entwicklungsprozess: Kapitel 2 und 3 legen die theoretischen Grundlagen zur Repräsentation der in dieser Arbeit betrachteten Modalitäten, Transformern und multimodaler Fusion und ordnen die Arbeit in den aktuellen Forschungsstand ein. Kapitel 4 beschreibt die Datenbasis, die Architektur von CrossBERT sowie das experimentelle Design. In Kapitel 5 werden die Ergebnisse der quantitativen Evaluation und der Ablationsstudien präsentiert. Abschließend diskutiert Kapitel 6 die Erkenntnisse und gibt einen Ausblick.

1.4 Voraussetzungen an den Lesenden

Die Arbeit setzt grundlegende Kenntnisse im überwachten maschinellen Lernen voraus, insbesondere zu Klassifikationsproblemen, Trainings-, Validierungs- und Testverfahren sowie gängigen Evaluationsmetriken. Zudem wird ein Basisverständnis neuronaler Netze, insbesondere der Transformer-Architektur, angenommen. Zentrale Begriffe wie Token, Embedding, Attention und Cross-Attention werden in Kapitel 2.1 und Kapitel 2.2 kurz zusammengefasst, um eine einheitliche Begriffsbasis zu schaffen. Spezialisiertes Vorwissen zum Versicherungsrecht oder zu internen Prozessen der Regressbearbeitung wird nicht vorausgesetzt.

2 Theoretische Grundlagen

2.1 Multimodale Daten

Eine *Modalität* bezeichnet eine eigenständige Form der Informationsrepräsentation mit eigener Struktur (z. B. sequenzieller Text vs. tabellarische Attribute). Multimodales Lernen zielt darauf ab, diese verschiedenen Quellen gemeinsam zu verarbeiten, um ein umfassenderes Bild eines Sachverhalts zu gewinnen, als es durch eine einzelne Modalität möglich wäre [BAM19].

Zentral sind dabei zwei Aufgaben [L⁺24]: *Alignment* und *Fusion*. Alignment stellt die inhaltliche Beziehung zwischen den Modalitäten her (z. B. Zuordnung von Text zu Tabellenwerten), während Fusion die Informationen zu einer gemeinsamen Repräsentation verknüpft. Durch diese Kombination können sich die Modalitäten gegenseitig ergänzen und Wissenslücken schließen, die bei isolierter Betrachtung bestehen bleiben würden.

2.1.1 Heterogenität in multimodalen Daten

Die Kombination von Text- und Tabellendaten stellt hierbei eine besondere Herausforderung dar. Während Text linguistisch strukturiert ist und Semantik aus der Reihenfolge von Tokens gewinnt, sind Tabellen attributbasiert und nicht-sequenziell. Dieser Unterschied, in der Literatur auch „Manifold Mismatch“ genannt, führt dazu, dass Text und Tabellen in sehr unterschiedlichen Zahlenräumen beschrieben werden [BAM19, HKCK20]. Text liegt in dichten Embedding-Vektoren, Tabellendaten in heterogenen, oft schlecht skalierten Merkmalen. Aus diesem Grund kann man Self-Attention, wie sie bei Text gut funktioniert, nicht einfach direkt auf rohe Tabellendaten anwenden.

Die zentrale Herausforderung besteht somit darin, diese strukturelle Lücke zu überbrücken. Bevor eine Fusion technisch möglich ist, müssen beide Modalitäten in einen kompatiblen, gemeinsamen Vektorraum projiziert werden. Dies erfordert allerdings spezifische Repräsentationsstrategien. Während für Text schon etablierte Tokenisierungsverfahren existieren, müssen für tabellarische Daten erst analoge Methoden der Tokenisierung angewendet werden, um sie in eine verarbeitbare Sequenzform zu überführen. Die nächsten Abschnitte beschreiben, wie Text (Abschnitt 2.1.2) und Tabellen (Abschnitt 2.1.3) in dieser Arbeit konkret dargestellt werden.

2.1.2 Repräsentation von Textdaten

Um das Verständnis der nachfolgenden Architekturen und der später beschriebenen Tabular Tokenization zu erleichtern, werden zunächst die zentralen Begriffe Token, Repräsentation und Embedding als gemeinsame Grundlage definiert:

- **Token:** Ein Token stellt die kleinste diskrete Einheit einer Eingabesequenz dar, in die Rohdaten zerlegt werden, bevor sie ein Modell verarbeitet. Während dies im Textbereich Wörter oder Wortteile (Sub-words) sein können [DCLT19], werden in multimodalen Modellen auch Bild-Patches [DBK⁺21] als Tokens behandelt. Im Modell dienen Tokens als eindeutige Identifikatoren (Token IDs), die eine Verbindung zwischen Rohdaten und ihrer mathematischen Repräsentation (Vektoren) herstellen.
- **Repräsentation:** Unter Repräsentation wird allgemein jede numerische Kodierung (Vektorisierung) von Informationen verstanden, die es einem Modell erlaubt, Semantik, Struktur oder Merkmale von Daten mathematisch zu erfassen. Dazu zählen sowohl manuell definierte Merkmalsräume (z. B. Bag-of-Words oder Term Frequency-Inverse Document Frequency (TF-IDF)) als auch gelernte Vektoren [AU22].
- **Embedding:** Ein Embedding ist eine spezielle Form der Repräsentation: eine gelernte, dichte Vektorkodierung, deren Koordinaten als Modellparameter optimiert werden. Man unterscheidet zwischen statischen Einbettungen (z. B. Word2Vec [MCCD13]), die jedem Wort unabhängig vom Kontext einen festen Vektor zuordnen, und *kontextualisierten Embeddings* (z. B. Bidirectional Encoder Representations from Transformers (BERT) [DCLT19]), bei denen die Bedeutung eines Tokens dynamisch aus seinem umgebenden Kontext abgeleitet wird.

Entwicklung der Textrepräsentation Historisch wurden Textdaten zunächst mit frequenzbasierten Verfahren wie dem Bag-of-Words-Modell oder der TF-IDF beschrieben [SB88]. Diese Ansätze bilden Dokumente als Vektoren von Worthäufigkeiten ab, berücksichtigen aber kaum Grammatik oder semantische Beziehungen zwischen Wörtern und führen häufig zu hochdimensionalen, dünn besetzten Vektoren.

Einen wichtigen Schritt brachten verteilte Wortrepräsentationen wie Word Embeddings, insbesondere das Word2Vec-Verfahren [MCCD13]. Wörter werden dabei in einen dichten, niedrigdimensionalen Vektorraum projiziert, der durch einfache neuronale Netze gelernt wird. Semantisch ähnliche Wörter liegen in diesem Raum nah beieinander. Ein Nachteil dieser statischen Embeddings bleibt jedoch bestehen: Jedes Wort erhält unabhängig vom Kontext denselben Vektor, sodass Mehrdeutigkeiten nur eingeschränkt abgebildet werden können.

Kontextuelle Embeddings wie Embeddings from Language Models (ELMo) [PNI⁺18] und später BERT [DCLT19] lösen dieses Problem, weil sie Wortvektoren abhängig vom jeweiligen Satzkontext berechnen. BERT wird als Encoder-only-Modell auf großen Textmengen vortrainiert und nutzt dabei die Transformer-Architektur sowie Self-Attention-Mechanismen (siehe Abschnitt 2.2), um für jedes Token eine kontextabhängige Repräsentation zu erzeugen.

Für die Verarbeitung ganzer Sätze oder Dokumente, wie sie in dieser Arbeit relevant ist, stoßen reine Token-Embeddings jedoch an Grenzen. Hier kommen Techniken wie Pooling oder die Verwendung spezieller Tokens ins Spiel. Insbesondere das $[CLS]$ -Token (Classifier Token) in Modellen wie BERT wird jeder Eingabesequenz vorangestellt, sammelt über Self-Attention kontextuelle Informationen und sein finaler Vektor $T_{[CLS]}$ dient als kompakte Satzrepräsentation für Klassifikationsaufgaben [DCLT19]. In dieser Arbeit wird das $[CLS]$ -Token als kompakte Textrepräsentation genutzt, um Textinformationen später mit tabellarischen Merkmalen zu kombinieren.

2.1.3 Repräsentation tabellarischer Daten

Tabellarische Daten bilden die Grundlage zahlreicher Anwendungen in der Industrie, stellen jedoch für Deep-Learning-Ansätze eine besondere Herausforderung dar [BLS⁺24]. Um die in Abschnitt 2.1.1 beschriebene Lücke zu schließen, ist eine Transformation der rohen Tabellendaten in eine kompatible Vektor-Repräsentation notwendig.

Herausforderungen der Tabellenstruktur Tabellen enthalten unterschiedliche Arten von Merkmalen, z. B. numerische Größen wie Preis oder Alter und kategoriale Angaben wie Produkt oder Postleitzahl [BLS⁺24, BSP23].

Ein wichtiges Merkmal ist die Permutationsinvarianz von Spalten. Anders als Wörter in einem Satz haben die Spalten einer Tabelle keine natürliche Ordnung. Idealerweise sollte ein Modell daher robust gegenüber Vertauschungen der Feature Positionen sein, solange die Zuordnung von Wert und Feature Typ erhalten bleibt [GRKB21]. Viele praktische Deep Learning Modelle für Tabellendaten, einschließlich der in dieser Arbeit untersuchten, erfüllen dies nicht explizit und setzen eine feste Spaltenreihenfolge zwischen Training und Inferenz voraus. Im Unterschied zu Textsequenzen mit Tokenisierung verändert gleiche Permutation der Spalten in beiden Phasen die Bedeutung der tabellarischen Features jedoch nicht.

Grenzen klassischer Vorverarbeitungsmethoden In traditionellen Machine-Learning-Verfahren, wie Gradient Boosted Decision Trees (GBDTs), werden kategoriale Daten häufig mittels One-Hot Encoding (OHE) verarbeitet. Dabei wird eine kategoriale Variable mit der Kardinalität C in einen binären Vektor der Länge C transformiert. Für Deep-Learning-Modelle und insbesondere für die Integration in Transformer-Architekturen ist OHE jedoch oft unpraktisch: Die Vektoren werden sehr lang und enthalten fast nur Nullen [HKCK20, GRKB21]. Außerdem macht OHE keine inhaltlichen Beziehungen zwischen Kategorien sichtbar. Alle Kategorien werden als orthogonal betrachtet, das heißt, der Abstand zwischen allen Kategorien im Vektorraum ist identisch. Semantische Beziehungen, wie etwa die Ähnlichkeit zwischen den Kategorien „Auto“ und „LKW“ im

Vergleich zu „Apfel“, können durch OHE nicht abgebildet werden [HKCK20]. In dieser Arbeit wird OHE für kategoriale Merkmale trotzdem als einfache, verlustfreie Kodierung der Rohdaten genutzt. Die Verdichtung in einen sinnvollen latenten Raum übernimmt eine nachgelagerte Projektionsschicht, die aus den dünn besetzten Eingaben eine dichte Repräsentation lernt.

Auch einfache Multi-Layer Perceptrons (MLPs) stoßen auf rohen Daten an ihre Grenzen, da sie numerische Eingaben lediglich als skalare Werte betrachten und im ersten Schritt keine feature-spezifische Verarbeitung ermöglichen, wie sie beispielsweise für das Erlernen von Interaktionen zwischen spezifischen Features notwendig wäre [GRKB21].

Tabular Tokenization und Latenter Raum Der Prozess, tabellarische Daten in eine für Transformer verarbeitbare Sequenz zu überführen, wird im Folgenden als *Tabular Tokenization* bezeichnet [BLS⁺24, BSP23]. In dieser Arbeit bedeutet dies, dass eine Tabellenzeile x in eine kurze Folge von Vektoren umgewandelt wird, wie sie ein Sprachmodell erwartet:

$$\mathbf{E} = [\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_N] \quad \text{mit} \quad \mathbf{e}_i \in \mathbb{R}^H \quad (2.1)$$

Hierbei entspricht H der Dimension des Hidden-States des verwendeten Transformer-Modells (z. B. $H = 768$ bei BERT). Durch diese Angleichung der Dimensionen kann später Cross-Attention zwischen Text- und Tabellen-Tokens angewendet werden [BSP23]. Im Gegensatz zu OHE erlaubt dieser dichte Vektorraum das Erlernen semantischer Ähnlichkeiten, sodass verwandte Features im Vektorraum geometrisch näher beieinander liegen.

Es ist jedoch essenziell zu unterscheiden: Während bei Text-Tokens die Reihenfolge die semantische Bedeutung bestimmt, handelt es sich bei *Tabular Tokens* um eine künstlich erzeugte Sequenz ohne natürliche Ordnung. Die Sequenzform dient hier rein als technisches Konstrukt für die Attention-Verarbeitung, nicht als Träger syntaktischer Informationen.

Architekturen der Repräsentation Hinsichtlich der Struktur der erzeugten Sequenz lassen sich zwei Hauptstrategien unterscheiden, die den Unterschied zwischen spaltenweiser und zeilenweiser Verarbeitung verdeutlichen [BSP23]:

Der erste Ansatz, bekannt als **Feature Tokenization** (oder Column-wise Embeddings), bildet jedes Feature der Ursprungstabelle isoliert auf genau einen Token-Vektor ab. Dies wird beispielsweise im *TabTransformer* [HKCK20] oder im *SAINT*-Modell [SGS⁺21] angewendet. Die Sequenzlänge N entspricht hierbei exakt der Anzahl der Spalten. Der Vorteil liegt in der Erhaltung der feingranularen Information jedes einzelnen Features.

Der zweite Ansatz, der in dieser Arbeit verfolgt wird, basiert auf einer **globalen Projektion** (Row-level Tokenization). Anstatt jedes Feature einzeln zu tokenisieren, werden hierbei alle Merkmale einer Tabellenzeile zunächst konkateniert und durch ein MLP in eine latente Repräsentation

überführt [GB21, BLS⁺24]. Diese Repräsentation besteht aus einer fixen Anzahl an Vektoren, wodurch die Sequenzlänge des Transformers von der Anzahl der Eingabefeatures entkoppelt wird. Ein wesentlicher Vorteil dieses Verfahrens ist, dass Zusammenhänge zwischen den Features bereits in der Projektionsphase erfasst werden können und die Rechenkomplexität der Attention-Schicht kontrollierbar bleibt.

Unabhängig von der gewählten Methode entsteht am Ende eine Sequenz dichter Vektoren. Erst dadurch können Transformer-Modelle die Tabellendaten mit denselben Operationen verarbeiten wie Text und sie anschließend über Mechanismen wie Cross-Attention mit Textrepräsentationen verknüpfen.

2.2 Transformer-Architekturen und Attention-Mechanismen

Nachdem im vorangegangenen Abschnitt die Grundlagen der Datenrepräsentation für Text und Tabellen erläutert wurden, geht es im nächsten Schritt um die Transformer-Architektur, die heute in vielen Natural Language Processing (NLP)-Anwendungen eingesetzt wird. Das Verständnis der Attention-Mechanismen ist wichtig, um die später verwendete multimodale Fusion einordnen zu können. Ursprünglich wurde der Transformer für maschinelle Übersetzungsaufgaben konzipiert, hat sich aber als Standard für die Modellierung komplexer Abhängigkeiten in sequenziellen Daten etabliert [VSP⁺17].

2.2.1 Der Transformer-Encoder

Der *Transformer* wurde 2017 von Vaswani et al. vorgestellt [VSP⁺17]. Im Gegensatz zu früheren Modellarchitekturen, die primär auf Rekurrenz (z. B. RNNs, LSTMs) oder Faltung (CNNs) basierten, verzichtet der Transformer vollständig auf diese Mechanismen und nutzt stattdessen *Self-Attention* als zentrales Element. Die ursprüngliche Architektur besteht aus zwei Hauptkomponenten: einem Encoder, der die Eingabesequenz verarbeitet und in eine abstrakte Repräsentation überführt, und einem Decoder, der basierend darauf eine Ausgabesequenz generiert.

Für die Aufgabenstellung dieser Arbeit, bei der es um die Klassifikation von multimodalen Daten geht, ist vor allem der Encoder-Teil relevant. Encoder-only-Modelle, wie das in Abschnitt 2.1.2 vorgestellte BERT, nutzen einen Stapel von Transformer-Blöcken, um für jedes Eingabe-Token einen kontextualisierten Vektor zu berechnen [DCLT19]. Im Gegensatz zu statischen Embeddings, bei denen ein Wort stets denselben Vektor erhält, integriert der Transformer-Encoder Informationen aus dem gesamten Kontext der Sequenz in die Repräsentation jedes einzelnen Tokens und dient damit als leistungsfähiger Feature-Extraktor.

2.2.2 Scaled Dot-Product Attention

Das zentrale Element eines jeden Transformer-Blocks ist der Attention-Mechanismus. Er ermöglicht es dem Modell, die Relevanz verschiedener Teile der Eingabe für den aktuellen Verarbeitungsschritt dynamisch zu gewichten. Vaswani et al. formalisieren dies als *Scaled Dot-Product Attention* [VSP⁺17].

Vereinfacht gesagt vergleicht das Modell eine Abfrage (*Query* $\mathbf{Q}$) mit vielen möglichen Kontextstellen (*Keys* $\mathbf{K}$) und bildet dann eine gewichtete Summe der zugehörigen Werte (*Values* $\mathbf{V}$). Tokens, die besser zur Query passen, erhalten höhere Gewichte. Mathematisch wird dies durch folgende Gleichung ausgedrückt:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right) \mathbf{V} \quad (2.2)$$

Hierbei berechnet das Skalarprodukt $\mathbf{Q}\mathbf{K}^T$ die Ähnlichkeit zwischen der Query und den Keys. Der Faktor $\frac{1}{\sqrt{d_k}}$ dient der Skalierung, um numerische Instabilitäten bei großen Dimensionen zu vermeiden [VSP⁺17]. Die Softmax-Funktion normalisiert diese Ähnlichkeitswerte zu Wahrscheinlichkeiten, die sich zu 1 aufsummieren. Schließlich wird eine gewichtete Summe der Values $\mathbf{V}$ gebildet.

2.2.3 Self-Attention vs. Cross-Attention

Ein wesentlicher Aspekt moderner Transformer-Architekturen und insbesondere multimodaler Modelle ist die Definition der Quellen für die Vektoren $\mathbf{Q}$, $\mathbf{K}$ und $\mathbf{V}$. Hierbei wird zwischen *Self-Attention* und *Cross-Attention* unterschieden.

Self-Attention (Intra-Modal) Im Standard-Encoder, wie er von Vaswani et al. [VSP⁺17] beschrieben wird, stammen Query, Key und Value aus derselben Eingabequelle (z. B. der Ausgabe des vorherigen Layers). Dies wird als Self-Attention bezeichnet.

- **Funktionsweise:** Jedes Token der Sequenz berechnet seine Aufmerksamkeit in Bezug auf alle anderen Tokens derselben Sequenz.
- **Zweck:** Modellierung von Abhängigkeiten innerhalb einer Modalität. Dies erlaubt dem Modell, kontextuelle Beziehungen, wie etwa Referenzen innerhalb eines Satzes, zu erfassen.

Cross-Attention (Inter-Modal) Für die Fusion unterschiedlicher Modalitäten, wie Text und Tabellendaten, ist die Cross-Attention von zentraler Bedeutung. Dieses Konzept findet sich in diversen multimodalen Architekturen [TB19].

- **Funktionsweise:** Die Vektoren werden aus unterschiedlichen Quellen gespeist. Beispielsweise generiert Modalität A (z. B. Text) die Queries $\mathbf{Q}$, während Modalität B (z. B. Tabelle) die Keys $\mathbf{K}$ und Values $\mathbf{V}$ bereitstellt.
- **Zweck:** Ermöglichung eines Informationsflusses über Modalitätsgrenzen hinweg. Die Text-Repräsentationen können gezielt Informationen aus den Tabellen-Features integrieren, die für den aktuellen Kontext relevant sind. Dies bildet das theoretische Fundament für flexible Fusions-Architekturen, da es eine dynamische Verknüpfung heterogener Datenräume erlaubt.

2.3 Strategien der multimodalen Fusion

Voraussetzung für jede Fusion ist, dass die unterschiedlichen Modalitäten bereits in einen kompatiblen Vektorraum transformiert wurden (vgl. Abschnitt 2.1). Die Strategien der multimodalen Fusion befassen sich anschließend mit der Frage, *wie* (Mechanismen) und *wann* (Architekturen) diese Informationen technisch kombiniert werden [L⁺24, BAM19].

2.3.1 Mechanismen der Fusion

Die technische Realisierung der Fusion, also *wie* die Vektoren der unterschiedlichen Modalitäten zusammengeführt werden, kann durch verschiedene mathematische Operationen erfolgen [J⁺24, BAM19]. Ein zentrales Konzept ist hierbei die *Joint Representation*. Das Ziel ist es, die unimodalen Eingangsvektoren in einen gemeinsamen semantischen Unterraum zu projizieren, um eine einzige, multimodale Repräsentation $\mathbf{Z}$ zu erzeugen [J⁺24, L⁺24]. Mathematisch lässt sich dieser Vorgang allgemein formulieren als:

$$\mathbf{Z} = f(\mathbf{X}_{\text{text}}, \mathbf{X}_{\text{tab}}) \quad (2.3)$$

Wobei f eine Funktion darstellt (beispielsweise ein neuronales Netz oder eine deterministische Operation), die aus den unimodalen Repräsentationen $\mathbf{X}_{\text{text}}$ und $\mathbf{X}_{\text{tab}}$ die fusionierte multimodale Repräsentation $\mathbf{Z}$ berechnet [BAM19].

Zu den gängigsten spezifischen Operationen zählen:

Konkatenation (Verkettung) Dies ist die wohl einfachste Form der Fusion, bei der die Merkmalsvektoren lediglich hintereinander gehängt werden:

$$\mathbf{Z} = [\mathbf{X}_{\text{text}} \parallel \mathbf{X}_{\text{tab}}] \quad (2.4)$$

Ein wesentlicher Vorteil ist, dass die Eingangsvektoren $\mathbf{X}_{\text{text}}$ und $\mathbf{X}_{\text{tab}}$ nicht dieselbe Dimension besitzen müssen. Die Dimension des Ergebnisvektors $\mathbf{Z}$ entspricht der Summe der Einzeldimensionen.

Addition (Summierung) Hierbei werden die Vektoren elementweise addiert:

$$\mathbf{Z} = \mathbf{X}_{\text{text}} + \mathbf{X}_{\text{tab}} \quad (2.5)$$

Dies setzt zwingend voraus, dass beide Vektoren dieselbe Dimension aufweisen, weshalb oft eine vorherige Projektion notwendig ist.

Attention-Mechanismen Im Gegensatz zu statischen Operationen wie der Addition oder Verkettung erlauben Attention-Mechanismen eine dynamische Gewichtung der Features. Besonders relevant ist die *Cross-Attention*. Hierbei können Repräsentationen einer Zielmodalität (z. B. Text) gezielt Informationen aus einer Quellmodalität (z. B. Tabelle) abfragen. Typischerweise stammen dabei die *Queries* aus der Zielmodalität, während *Keys* und *Values* aus der Quellmodalität geliefert werden. Dies ermöglicht eine gewichtete Aggregation von Informationen, die auf den aktuellen Kontext konditioniert ist, und erlaubt die Modellierung komplexer Abhängigkeiten über Modalitätsgrenzen hinweg [L⁺24].

2.3.2 Architekturen und Positionierung der Fusion

Neben der gewählten Operation ist wichtig, *an welcher Stelle* im Modell die Fusion stattfindet (früh, spät oder mehrfach in der Tiefe) [J⁺24, L⁺24, BAM19].

Early Fusion (Daten- und Feature-Ebene) Bei der Early Fusion werden die Modalitäten auf Rohdaten- oder Feature-Ebene zu einer gemeinsamen Eingabe kombiniert und anschließend in einem gemeinsamen Modellzweig (*One-Tower*) weiterverarbeitet [J⁺24, L⁺24, BAM19]. Dadurch können Interaktionen zwischen Merkmalen früh und kontextübergreifend gelernt werden, jedoch steigen die Anforderungen an Ausrichtung und Kompatibilität der Modalitäten; bei stark heterogenen Eingaben kann dies die Modellierung erschweren [BAM19, J⁺24].

Late Fusion (Entscheidungs- und Ausgabe-Ebene) Bei der Late Fusion werden Text und Tabelle zunächst in getrennten Zweigen (*Two-Tower*) verarbeitet und erst am Ende über ihre High-Level-Repräsentationen oder Prädiktionen kombiniert [L⁺24]. Typische Operatoren sind Mittelwertbildung, Voting oder ein nachgeschaltetes MLP [BAM19]. Der Ansatz ist modular und robust gegenüber fehlenden Modalitäten, modelliert jedoch kaum niedrigstufige Interaktionen; zudem wirken sich starke Störungen einer Modalität direkt auf die Endentscheidung aus [BAM19].

Hybrid und Deep Fusion Hybride Ansätze verbinden frühe und späte Fusion, indem sie zusätzliche Fusionsschichten zwischen getrennten Zweigen einfügen [J⁺24, BAM19, L⁺24]. In einigen Transformer-Modellen wird die Fusion über mehrere Layer hinweg wiederholt, häufig über Cross-Attention, sodass Interaktionen schrittweise verfeinert werden können [J⁺24, L⁺24].

3 Verwandte Arbeiten

Das Feld des multimodalen Lernens hat sich durch den Einsatz von Transformer-Modellen stark weiterentwickelt. Für Bild und Text gibt es inzwischen etablierte Verfahren auf Basis von Cross-Attention. Die gemeinsame Verarbeitung von tabellarischen Daten und Text ist dagegen noch relativ neu, und es gibt bisher keine klar dominierende Architektur. Dieses Kapitel ordnet die Arbeit in den aktuellen Forschungsstand ein, differenziert zwischen generellen Architekturen und spezifischen Ansätzen für Tabellen und stellt den im Unternehmenskontext relevanten Benchmark vor.

3.1 Cross-Attention in multimodalen Transformer-Architekturen

Cross-Attention ist ein wichtiger Baustein, um Informationen aus verschiedenen Datenquellen in Transformer-Modellen zusammenzubringen. Ein Modell kann damit gezielt Informationen einer Modalität in den Kontext einer anderen Modalität einbeziehen, ohne die ursprüngliche Struktur der Eingaben zu früh zu vermischen.

Im Bereich Vision Language zeigt **LXMERT** [TB19], wie eine Dual-Stream-Architektur genutzt werden kann. Bild und Text werden zunächst getrennt encodiert. Erst danach führt ein zusätzlicher Cross-Modality-Encoder beide Stränge zusammen. So bleiben mehr Informationen erhalten, als wenn man Bild- und Textdaten direkt am Eingang einfach aneinanderhängt.

Flamingo [ADL⁺22] geht noch einen Schritt weiter. Das Modell richtet sich auf Few-Shot-Szenarien und verwendet ein vortrainiertes Sprachmodell, das eingefroren bleibt. Visuelle Informationen werden über *Gated-Cross-Attention-Dense*-Schichten in dieses Sprachmodell eingespeist. Das zeigt, dass man Cross-Attention auch nachträglich an ein bestehendes Sprachmodell anbinden kann. Neuere Ansätze wie **PaLI** [C⁺23] bestätigen, dass solche dynamischen Interaktionen statischen Fusionsverfahren überlegen sind, wenn komplexe semantische Zusammenhänge zwischen Modalitäten modelliert werden sollen.

3.2 Verarbeitung von Tabellen und Text mit Transformern

Die Übertragung dieser Ideen auf Tabellen ist schwieriger, da tabellarische Daten im Gegensatz zu Text keine natürliche Reihenfolge der Einträge besitzen und heterogene Spaltentypen kombinieren (siehe Abschnitt 2.1.1).

Der **TabTransformer** [HKCK20] zeigt, dass Transformer Encoder auch für rein tabellarische, insbesondere kategoriale, Daten geeignet sind. Jede Spalte wird dabei als eigener Token betrachtet (Feature Tokenization), und Self-Attention modelliert Abhängigkeiten zwischen den Spalten.

Obwohl TabTransformer keine Textdaten einbezieht, bildet er die Grundlage für spätere Arbeiten mit spaltenweiser Attention.

Für die Kombination von Tabellen und Text wählt **TaBERT** [YNYR20] einen anderen Weg. Tabellenzeilen werden in textähnliche Sequenzen linearisiert und gemeinsam mit natürlichsprachlichen Beschreibungen in ein BERT-Modell gegeben. Das entspricht einer frühen Fusion: Tabelle und Text werden schon auf Eingabeebene zu einer gemeinsamen Sequenz zusammengeführt. Die ursprüngliche Tabellenstruktur ist dann nur noch indirekt erkennbar.

Arbeiten wie das **Multimodal-Toolkit** [GB21] und Bonnier et al. [B⁺24] vergleichen verschiedene Architekturen. Bonnier et al. zeigen, dass spezialisierte multimodale Transformer in der Praxis oft nur geringe Vorteile gegenüber einfachen Baselines bringen, etwa gegenüber der Konkatination von Text- und Tabellen-Features. Ein wichtiger Einflussfaktor ist dabei die Qualität der einzelnen Modalitäten.

Industrieller Benchmark: CrossFitter Stacking Im Unternehmenskontext dieser Arbeit dient die interne Modellarchitektur „CrossFitter“ als ebenfalls relevante Baseline. Diese Architektur wurde im Rahmen eines Praktikums bei der Firma QuantCo entwickelt und in einer internen Präsentation vorgestellt [Fue24]. Im Gegensatz zu den zuvor beschriebenen End-to-End-Architekturen handelt es sich um einen zweistufigen Stacking-Ansatz, der die Stärken spezialisierter Modelle kombiniert, ohne dass diese in einem gemeinsamen, durchgängig trainierbaren Modell vereint sind. Abbildung 8 im Anhang A1 zeigt den schematischen Aufbau der CrossFitter-Modellarchitektur, basierend auf der internen Dokumentation [Fue24]. In den Experimenten dieser Arbeit wird CrossFitter jedoch nicht als direkte Vergleichsbaseline genutzt, da der produktive Stacking-Ansatz einem anderen Modellierungsprinzip folgt als die untersuchten End-to-End-Transformer-Modelle und die zugrunde liegende Pipeline nicht vollständig reproduzierbar ist.

Das Verfahren nutzt ein **2-Fold-Cross-Prediction-Schema**, um Textinformationen für ein tabellarisches Modell nutzbar zu machen:

1. Die Trainingsdaten werden in zwei Folds A und B aufgeteilt.
2. Ein BERT-Modell wird auf Fold A trainiert und erzeugt Vorhersagen für Fold B, also Out-of-Sample Predictions.
3. Analog wird ein zweites BERT-Modell auf Fold B trainiert und sagt die Fälle in Fold A voraus.

Die so gewonnenen Wahrscheinlichkeitswerte des Textmodells werden als zusätzliches Feature zusammen mit den ursprünglichen strukturierten Merkmalen in eine Light Gradient Boosting

Machine (LGBM) eingespeist. In der Praxis ist dieser Ansatz robust und leistungsfähig. Aus theoretischer Sicht bleibt jedoch eine Einschränkung bestehen, da die Modalitäten während des Trainings nicht direkt miteinander interagieren. Das Textmodell erhält keinen Rückfluss aus den Tabellendaten und kann seine Repräsentationen daher nicht an den Kontext der strukturierten Attribute anpassen.

3.3 Forschungslücke und Einordnung

In den betrachteten Arbeiten zeigt sich ein deutliches Bild:

- Für Bild und Text gibt es ausgereifte Cross-Attention-Architekturen (z. B. Flamingo).
- Für Tabelle und Text dominieren bisher Linearisierungsansätze (z. B. TaBERT) oder alternative Architekturen wie das vorgestellte Stacking-Verfahren (z. B. CrossFitter).

Für Tabular-Text-Kombinationen ist bisher nur begrenzt untersucht, wann Cross-Attention gegenüber einfachen Fusionsoperationen tatsächlich einen Mehrwert bringt und wie man solche Mechanismen sinnvoll im Modell platziert. Diese Arbeit greift diese Fragen auf und untersucht exemplarisch Cross-Attention-basierte Architekturen für Versicherungsdaten.

4 Methodik

4.1 Datenbasis und Vorverarbeitung

Die Datengrundlage besteht aus einer Mischung aus produktiven Versicherungsdaten und öffentlichen Benchmarks. Alle Datensätze werden über eine einheitliche Pipeline in Tensoren überführt (inkl. Splitting, tabellarischer Vorverarbeitung und Text-Tokenisierung).

Datenbasis Der primäre Datensatz stammt aus einem deutschen Versicherungsunternehmen und wurde für die Identifikation von Regresspotenzialen aufbereitet. Es handelt sich um ein Multi-Class-Setting mit den Zielklassen *Kein Regress* (0), *Regress* (1) und *Versicherungsschutzentzug* (2). Er kombiniert unstrukturierte Schadenbeschreibungen mit tabellarischen Merkmalen zum Schadenfall (Tabelle 1 zeigt einen exemplarischen Datenpunkt). Die Daten bergen jedoch eine Problematik: Es wurde historisch nur ein Teil der Fälle für eine ausführliche Regressprüfung ausgewählt, was zu einem *Selection Bias* in den Labels führt. Die nicht geprüften Daten enthalten wahrscheinlich noch unerkannte Regressfälle, auch wenn davon ausgegangen wird, dass dieses Potenzial gering ist (*Missing-Label-Problem*). Ungelabelte Fälle werden daher als Klasse 0 behandelt. Diese Problematiken (Bias und Missing Labels) sind nicht der Hauptfokus dieser Arbeit, werden aber der Vollständigkeit halber erwähnt, um die Eigenschaften des primären Datensatzes transparent zu machen.

Tab. 1: Exemplarischer Datensatz der internen Regressdatenbasis (anonymisiert).

Metadaten	ID: 68443XXXX, Label: 1 (Regress), Status: Validiert (True)		
Textmodalität	<i>Schadenhergang</i> : VN: Kreuzung: Vn hatte grünen Pfeil der aufgeleuchtet sei. Es kam zur Kollision Vorgang strittig. <i>Dokumente</i> : ausführliche HSA, strittige Ampel, PUM, EA-Geb-re io. <i>Notizen</i> : PWS empfiehlt Beauftragung eines SV; ADAC bereits auf dem Weg; wst wartet auf fg...		
Tabellarische Merkmale	log_zlg_fzg: 9,839, kh_other_partially_paid: 1, undersparte: KF.VK, risikoschluessel: UNF, svorg_schadenursache: Unfall ein weiteres Kfz, had_ever_erinnerungsregress: 1		

Zur externen Validierung werden zwei Kaggle-Benchmarks genutzt:

1. **Women's E-Commerce Clothing Reviews** [Kag18]: Binäre Sentiment-Klassifikation (Positive vs. Negative Reviews) mit Text und Metadaten (23.486 Samples gesamt; 21.137 Training, 2.349 Validierung).
2. **PetFinder.my Adoption Prediction** [Kag19]: Ordinale Multi-Class-Klassifikation der Adoptionsgeschwindigkeit (Klassen 0 bis 4) auf Basis von Beschreibungen und Metadaten (14.993 Samples gesamt; 13.494 Training, 1.499 Validierung).

Damit wird die Übertragbarkeit der Architektur außerhalb der Versicherungsdomäne überprüft.

Datenvorverarbeitung Die Vorverarbeitung trennt strikt Trainings-, Validierungs- und Testdaten, um Data Leakage zu vermeiden. Das Splitting erfolgt stratifiziert (bei Multi-Class) und verwendet, sofern verfügbar, einen vordefinierten Testsplit. Zusätzlich wird aus dem Trainingssplit ein Validierungsanteil (`validation_fraction`) abgeleitet. Optional wird die Klassenverteilung im Training über Undersampling der Majoritätsklasse auf ein vorgegebenes Verhältnis $N(0)/N(1)$ (`train_imbalance_0_to_1`) eingestellt. Im Wesentlichen umfasst die Vorverarbeitung:

- **Tabellarische Daten:** OHE für kategoriale Merkmale (fehlende Werte als Kategorie `None`, unbekannte Kategorien werden ignoriert); Min-Max-Skalierung numerischer Variablen auf $[0, 1]$. Die Encoder/Scaler werden ausschließlich auf Trainingsdaten trainiert (*fit*) und auf Validierung/Test angewandt (*transform*).
- **Textdaten:** Tokenisierung mit `deepset/gbert-base` (inkl. `[CLS]` und `[SEP]`); Padding/Truncation auf die modellabhängige maximale Kontextlänge (für BERT: 512 Tokens).
- **Splitting und Balancing:** Stratified Split unter Beibehaltung der Klassenverteilung (insbesondere relevant bei Multi-Class, z. B. PetFinder). Im Training wird optional ein Random Undersampling der Majoritätsklasse eingesetzt, gesteuert über `train_imbalance_0_to_1`.

4.2 Baseline-Modelle

Um den Mehrwert der entwickelten CrossBERT-Architektur gegenüber bestehenden multimodalen Modellen einordnen zu können, erfolgt ein Vergleich mit zwei bestehenden multimodalen Modellen für die Fusion von tabellarischen Daten und Textdaten: SumBERT (Early Fusion) und ConcatBERT (Late Fusion). Die Konzepte, der Quellcode sowie die Architekturgrafiken (Abbildungen 1 und 2) dieser Modelle entstammen Vorarbeiten, die im Rahmen eines Praktikums bei der Firma QuantCo durchgeführt wurden [Fue24].

4.2.1 SumBERT (Early Fusion)

SumBERT führt die Tabelleninformation bereits vor dem Encoder in das Modell ein. Die vorverarbeiteten Tabellendaten, repräsentiert als Merkmalsvektor $\mathbf{x}_{\text{tab}} \in \mathbb{R}^F$, werden zunächst per linearer Projektion (realisiert durch ein MLP) in den Vektorraum des Sprachmodells projiziert. Die Dimension der Projektion entspricht der Hidden-Size des Modells ($H = 768$). Dieser projizierte Vektor wird anschließend elementweise zum Embedding des $[\text{CLS}]$ -Tokens addiert, bevor die Sequenz den ersten Transformer-Layer durchläuft (siehe Abbildung 1).




Abb. 1: Architektur von SumBERT: Addition der Tabellen-Repräsentation zum CLS-Token-Embedding vor dem Encoder. Quelle: [Fue24].

Formal lässt sich die Berechnung des fusionierten Eingabevektors $\mathbf{e}_{\text{fused}}^{[\text{CLS}]}$ wie folgt beschreiben:

$$\mathbf{e}_{\text{fused}}^{[\text{CLS}]} = \mathbf{e}_{\text{text}}^{[\text{CLS}]} + \text{MLP}_{\text{tab}}(\mathbf{x}_{\text{tab}}) \quad (4.1)$$

Hierbei bezeichnet $\mathbf{e}_{\text{text}}^{[\text{CLS}]} \in \mathbb{R}^H$ das ursprüngliche Embedding des $[\text{CLS}]$ -Tokens (Eingabe-Ebene) und $\mathbf{x}_{\text{tab}}$ den Vektor der tabellarischen Features. Durch diese Addition trägt das $[\text{CLS}]$ -

Token von Beginn an sowohl Text- als auch Tabelleninformationen und gibt diese über die Self-Attention im Encoder an tiefere Schichten weiter.

4.2.2 ConcatBERT (Late Fusion)

Im Gegensatz dazu nutzt ConcatBERT eine späte Fusion (Late Fusion). Text- und Tabellendaten werden hierbei zunächst separat verarbeitet. Der Text durchläuft den vollständigen BERT-Encoder, um eine kontextualisierte Repräsentation des [CLS]-Tokens zu generieren, die im Folgenden als $\mathbf{h}_{\text{text}}^{[\text{CLS}]}$ bezeichnet wird. Wir verwenden hier $\mathbf{h}$ (statt $\mathbf{e}$), um zu kennzeichnen, dass es sich um einen Hidden State der Ausgabe-Ebene handelt. Erst im Anschluss an den Encoding-Prozess wird dieser Vektor mit den vorverarbeiteten Tabellen-Features $\mathbf{x}_{\text{tab}}$ konkateniert (siehe Abbildung 2).




Abb. 2: Architektur von ConcatBERT: Konkatenation der Tabellen-Features mit dem Output des BERT-Encoders. Quelle: [Fue24].

Der resultierende Vektor $\mathbf{h}_{\text{fusion}}$ dient als Eingabe für den Klassifikations-Head:

$$\mathbf{h}_{\text{fusion}} = [\mathbf{h}_{\text{text}}^{[\text{CLS}]} \parallel \mathbf{x}_{\text{tab}}] \quad (4.2)$$

Diese Architektur ist rechnerisch effizient und leicht zu implementieren, führt aber dazu, dass die Tabellendaten nicht mit dem Self-Attention-Mechanismus des Transformers interagieren können.

4.3 CrossBERT-Architektur

Die CrossBERT-Architektur erweitert einen BERT-Klassifikator um Cross-Attention zwischen Text und Tabellendaten. Anders als bei SumBERT und ConcatBERT (Abschnitt 4.2) werden Tabellendaten nicht nur als statischer Zusatzvektor verwendet, sondern als kurze Token-Sequenz in den Hidden-Space von BERT projiziert, die der Text über Cross-Attention auslesen kann (vgl. Abschnitt 2.2).

4.3.1 Architekturüberblick

Abbildung 3 zeigt den Gesamtaufbau. Text wird mit `deepset/gbert-base` in eine Sequenz von Embeddings überführt und durch den Encoder verarbeitet. Die Dimension der Hidden-States beträgt dabei $H = 768$. Parallel dazu werden die tabellarischen Features durch einen *TabularTokenizer* in eine Sequenz von N Vektoren, die sogenannten *Tab Tokens*, kodiert. Kern der Architektur ist die Fusion über Cross-Attention-Blöcke. Diese verknüpfen gezielt das `[CLS]`-Token des Textes mit der Sequenz der Tab Tokens. Dies kann an zwei Stellen erfolgen: (i) *Early Fusion* direkt auf den Eingangs-Embeddings vor dem Encoder oder (ii) *Late Fusion* auf dem finalen Status nach dem Encoder. Der Klassifikationskopf (Classification Head) arbeitet anschließend auf dem fusionierten `[CLS]`-Vektor.

4.3.2 TabularTokenizer

Die tabellarische Eingabe liegt nach der Vorverarbeitung für einen Batch der Größe B als Matrix $\mathbf{X}_{\text{tab}} \in \mathbb{R}^{B \times F}$ vor, wobei F die Anzahl der Features (normalisierte numerische und One-Hot-kodierte kategoriale Variablen) bezeichnet.

Analog zur in Abschnitt 2.1.3 beschriebenen globalen Projektion werden aus diesen Features N latente Tokens generiert. Das Ergebnis ist ein Tensor $\mathbf{E}_{\text{tab}} \in \mathbb{R}^{B \times N \times H}$, der eine Sequenz von N Vektoren der Dimension H darstellt (siehe Abbildung 4a):

$$\mathbf{e}_i = \text{MLP}_i(\mathbf{X}_{\text{tab}}) \quad \text{für } i = 1, \dots, N \quad (4.3)$$

Die Gesamtsequenz ergibt sich durch Konkatenation der einzelnen Projektionen:

$$\mathbf{E}_{\text{tab}} = [\mathbf{e}_1, \dots, \mathbf{e}_N] \quad (4.4)$$

Technisch wird dies durch N parallele, lernbare MLP-Projektionsköpfe realisiert. Jeder Kopf bildet den gesamten Feature-Vektor $\mathbf{X}_{\text{tab}}$ auf einen eigenen Token-Vektor $\mathbf{e}_i$ ab. Die N Projektionsköpfe erzeugen somit N unterschiedliche, gelernte „Ansichten“ auf dieselbe Tabellenzeile.




Abb. 3: Architektur von CrossBERT mit optionaler Early- und Late-Cross-Attention über Tab Tokens.

Diese globale Projektion entkoppelt die Sequenzlänge von der Eingabedimension F , die durch One-Hot-Encoding stark anwächst. Während eine direkte Tokenisierung aller Spalten oder eine Gruppierung nach Originalfeatures (wie beim später vorgestellten *TabTokenizer V2*) zu variablen Sequenzlängen führt, garantiert die fixe Anzahl N (Hyperparameter `num_tab_token`) eine konstante Recheneffizienz. Dies zwingt das Modell, die relevantesten Informationen der hochdimensionalen Tabellendaten in eine kompakte latente Repräsentation zu komprimieren.

4.3.3 Cross-Attention-Block

Die Fusion der Modalitäten erfolgt über einen Cross-Attention-Mechanismus (siehe Abschnitt 2.2), der gezielt in den Datenfluss des Transformers integriert ist. Wie in Abbildung 3 dargestellt, beginnt der Prozess mit der **CLS Extraction**, bei der das [CLS]-Token aus der aktuellen Sequenz (entweder Embedding oder Hidden State) herausgelöst wird. Dieses extrahierte Token fungiert als *Query*, während die erzeugten Tab Tokens als *Keys* und *Values* dienen. Nach der Anreicherung durch die Attention-Operation wird das aktualisierte Token mittels **CLS Replacement** an seine ursprüngliche Position in die Sequenz zurückgeschrieben, um den weiteren Fluss im Modell zu durchlaufen.

Sei $\mathbf{c} \in \mathbb{R}^{B \times 1 \times H}$ der Vektor des [CLS]-Tokens (abhängig von der Position der Fusion entweder das initiale Embedding oder der Encoder-Output) und $\mathbf{E}_{\text{tab}} \in \mathbb{R}^{B \times N \times H}$ die Sequenz der Tab Tokens. Die Projektionen für den Attention-Mechanismus berechnen sich wie folgt:

$$\mathbf{Q} = \mathbf{c}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{E}_{\text{tab}}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{E}_{\text{tab}}\mathbf{W}_V \quad (4.5)$$

Hierbei sind $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{H \times H}$ die lernbaren Gewichtsmatrizen. Über die Attention-Gewichte lernt das Modell dynamisch, welche Informationen aus den Tabellendaten für die Interpretation des aktuellen Textes relevant sind. Die [CLS]-Repräsentation wird so kontextabhängig um tabellarische Informationen angereichert.

Die CrossBERT-Implementierung nutzt Multi-Head Attention und ergänzt diese um Residualpfade sowie ein Feed-Forward-Netzwerk (Abbildung 4b). Optional kann eine Tab-Maske genutzt werden, um einzelne Tab Tokens in der Attention auszublenden.

Die Beschränkung der Cross-Attention auf das [CLS]-Token statt auf alle Texttokens ist bewusst gewählt. Erstens reduziert sie die Rechenkomplexität, weil nur ein Textvektor mit den Tab Tokens interagiert und nicht die gesamte Sequenz. Zweitens zielt die Aufgabe auf eine Entscheidung auf Dokumentebene. Das [CLS]-Token bündelt die Bedeutung des gesamten Textes, sodass die Tabelleninformation direkt in diese Gesamtrepräsentation eingemischt wird.




Abb. 4: Komponenten der CrossBERT-Architektur: Links die Projektion der Features in Tab Tokens, rechts deren Integration via Cross-Attention.

4.3.4 Fusionsvarianten: Early, Late und Hybrid

Die Position des Cross-Attention-Blocks legt fest, ob die Fusion früh (vor dem Encoder), spät (nach dem Encoder) oder an beiden Stellen erfolgt:

- **Early Fusion:** Cross-Attention wird auf den `[CLS]`-Embedding-Vektor vor dem Encoder angewandt, sodass tabellarische Information die gesamte nachfolgende Kontextualisierung beeinflussen kann.
- **Late Fusion:** Cross-Attention wird erst auf den finalen Encoder- `[CLS]`-State angewandt, wodurch tabellarische Information als kontextabhängige Nachschärfung der Dokumentrepräsentation integriert wird.
- **Hybrid Fusion:** In dieser Arbeit kommt eine vereinfachte Hybrid-Fusion zum Einsatz: Early und Late Fusion werden kombiniert, um sowohl die Encoder-Features als auch die finale Entscheidungsschicht mit tabellarischen Informationen anzureichern.

Die Auswirkungen der Fusionsposition (Early/Late/Hybrid) sowie der Anzahl der Tab Tokens `num_tab_token` werden in gezielten Ablationsstudien systematisch untersucht (vgl. Abschnitt 4.5).

4.4 Trainings-Setup und Evaluationsmetriken

Damit die Modelle vergleichbar sind, werden alle Experimente mit einer gemeinsamen Pipeline und einer zentralen Konfiguration durchgeführt. Baselines und CrossBERT teilen sich dabei dieselben Trainingsparameter; sie unterscheiden sich nur in der Art der multimodalen Fusion (vgl. Abschnitt 4.3).

Modell und Lernstrategie. Als Textencoder wird `deepset/gbert-base` verwendet [CSM20]. GBERT ist ein vortrainiertes deutsches Sprachmodell auf Basis von BERT [DCLT19] und dient als Initialisierung für das end-to-end Fine-Tuning im jeweiligen Klassifikations-Setup. Als Verlustfunktion für das Training dient durchgängig Cross-Entropy-Loss; dies gilt auch für den ordinalen Petfinder-Datensatz, um die methodische Vergleichbarkeit aller Modelle sicherzustellen (vgl. Anhang A1.2).

Optimierung und Trainingsprotokoll. Die zentralen Trainingshyperparameter sind in Tabelle 2 zusammengefasst. Zur Stabilisierung des Fine-Tunings wird eine Lernratenstrategie aus linearem Warmup und anschließendem Cosine Scheduling eingesetzt. Das Early Stopping überwacht `val/average_precision`. Die Validierung wird in festen Intervallen innerhalb

einer Epoche ausgeführt (`val_check_interval=500`), sodass alle 500 Batches geprüft wird, ob das Early Stopping greifen soll. Für die *Gating*-Ablation nach Flamingo ([ADL⁺22], siehe Abschnitt 4.5) werden zusätzlich (i) der BERT-Encoder in den ersten zwei Epochen eingefroren (`freeze_bert_epochs=2`), (ii) die Gating-Parameter (`alpha_`) mit einer fünffach erhöhten Lernrate ohne Weight Decay trainiert (`lr_alpha_multiplier=5,0`) und (iii) die Epochenanzahl auf 2–6 begrenzt.

Tab. 2: Zentrale Trainingshyperparameter (Basiskonfiguration ohne Gating).

Parameter	Wert
Optimizer	AdamW
Lernrate	$1 \cdot 10^{-5}$
LR-Scheduler	Linear Warmup (0,1) + Cosine
Batchgröße (Train / Eval)	64 / 128
Epochen (min / max)	1 / 4
Early Stopping	Patience 5, Monitor <code>val/average_precision</code>
Validierungsanteil	<code>validation_fraction=0,2</code>

Validierung, Hardware und Mixed Precision. Die Validierung erfolgt auf einem festen Train/Val/Test-Split (vgl. Abschnitt 4.1). Alle Experimente laufen auf einer NVIDIA Tesla V100 (32 GB). Mixed Precision reduziert dabei Rechenzeit und Speicherbedarf.

Evaluationsmetriken. Als Hauptkennzahlen werden Average Precision (AP) und die Area Under the Receiver Operating Characteristic Curve (AUC-ROC) genutzt. AP ist bei unausgeglichene Klassen hilfreich, da sie die gesamte Precision-Recall-Kurve berücksichtigt. AUC-ROC misst, wie gut das Modell positive gegenüber negativen Beispielen trennt, unabhängig von einem festen Schwellenwert. In Multi-Class-Settings werden beide Kennzahlen one-vs-rest pro Klasse berechnet. Zusätzlich werden die Klassen binarisiert (positiv vs. Klasse 0), um eine konsistente Vergleichbarkeit über Datensätze hinweg zu gewährleisten.

Für den Petfinder-Datensatz wird zusätzlich der Quadratic Weighted Kappa (QWK) verwendet. Da es sich hierbei um ein ordinales Multi-Class-Problem handelt, können AP und AUC-ROC die Modellgüte nicht einwandfrei abbilden. Der QWK misst, wie gut die Vorhersagen mit den tatsächlichen Bewertungen (0 bis 4) übereinstimmen. Ein wesentliches Merkmal ist die quadratische Gewichtung von Fehlern: Grobe Abweichungen (z. B. Vorhersage 4 statt 0) werden deutlich stärker bestraft als kleine (z. B. 1 statt 0), da der quadratische Abstand zwischen den Klassen berücksichtigt wird.

Zur Beurteilung der Modelleffizienz werden zudem bei jedem Experiment die Anzahl der trainierbaren Parameter und die Floating Point Operations (FLOPs) protokolliert.

4.5 Ablationsstudien

Um den Einfluss einzelner Architektur-Entscheidungen systematisch zu verstehen, werden gezielte Ablationsstudien durchgeführt.

Tab. 3: Übersicht der geplanten Ablationsstudien

Ablation	Variable (Wertebereich)	Ziel
Cross-Attention	Position: Early / Late / Hybrid	Einfluss des Fusionsorts (vor/nach Encoder vs. kombiniert)
Tab Tokens	n_{tab} (Hybrid): 0 / 1 / 2 / 4 / 8 / 16	Quantitativ prüfen, wie stark n_{tab} die Leistung von CrossBERT (Hybrid) beeinflusst
Gating Layer	Flamingo-style [ADL ⁺ 22]: Mit / Ohne	Adaptive Gewichtung Text $\leftrightarrow$ Tab für stabilere Scores und ökonomische Kennzahlen
Tokenizer	TabTokenizer: V1 / V2 (per-Feature-Tokenisierung)	Prüfen, ob Tokenisierung pro Feature die Fusion und Interpretierbarkeit verbessert

Im Fokus stehen (i) die Positionierung der Cross-Attention (Early/Late/Hybrid) und (ii) die Sensitivität gegenüber der Anzahl der Tab Tokens n_{tab} im Hybrid-Setup. Darüber hinaus werden zwei methodische Erweiterungen untersucht:

Gated Cross-Attention. Zur Stabilisierung der Fusion wird ein Gating-Mechanismus nach dem Vorbild von Flamingo [ADL⁺22] eingeführt. Hierbei wird der Output der Cross-Attention-Schicht nicht direkt addiert, sondern durch einen lernbaren Skalar $\tanh(\alpha)$ gewichtet: $\mathbf{y} = \mathbf{x} + \tanh(\alpha) \cdot \text{Attention}(\mathbf{x}, \mathbf{E}_{\text{tab}})$. Da α mit 0 initialisiert wird, startet das Modell als reiner Text-Klassifikator und lernt schrittweise, tabellarische Informationen hinzuzufügen. Für diese Ablation wurden die im Flamingo-Ansatz beschriebenen trainingsseitigen Anpassungen übernommen (Encoder-Freezing und erhöhte Lernrate für die Gate-Parameter; vgl. Abschnitt 4.4), um die Stabilität zu gewährleisten.

TabTokenizer V2 (Per-Feature-Tokenisierung). Während der Standard-Tokenizer die gesamte Tabellenzeile global auf N latente Tokens projiziert, ordnet der *TabTokenizer V2* jedem semantischen Feature (z. B. einer numerischen Variable oder einer Gruppe von One-Hot-kodierten Spalten) genau ein eigenes Token zu. Entscheidend ist hierbei, dass über eine *Feature Map* zusammengehörige One-Hot-Spalten aggregiert werden, sodass die Anzahl der erzeugten Tokens exakt der Anzahl der ursprünglichen Features im Rohdatensatz entspricht (und nicht der Dimension der expandierten Matrix $\mathbf{X}_{\text{tab}}$). Jedes Feature erhält dazu einen eigenen, separaten MLP-Projektionskopf. Dies erhöht die Interpretierbarkeit, da jedes Element der Token-Sequenz direkt auf ein spezifisches Eingabefeature zurückzuführen ist.

5 Ergebnisse

Dieses Kapitel stellt die Ergebnisse der Experimente vor. Der Fokus liegt auf dem Vergleich der CrossBERT-Architektur mit den etablierten Baselines sowie der Analyse zentraler Designentscheidungen durch Ablationsstudien. Eine abschließende Explainability-Analyse illustriert exemplarisch die Interaktion zwischen Text- und Tabulardaten.

5.1 Hauptexperiment

Das Hauptexperiment evaluiert die Klassifikationsleistung auf dem primären Datensatz. Tabelle 4 fasst die zentralen Metriken (AUC-ROC, AP) sowie die Modellkomplexität (FLOPs, Parameter) zusammen.

Die Integration von Cross-Attention führt zu einer messbaren Leistungssteigerung gegenüber den Baselines. Während die AUC-ROC-Werte aller Modelle auf einem ähnlich hohen Niveau liegen, differenzieren sich die Architekturen in der AP deutlicher. Im Vergleich zu ConcatBERT (AP 0,579) erzielen alle CrossBERT-Varianten eine höhere Präzision. Auch gegenüber der starken SumBERT-Baseline (AP 0,601) erreicht insbesondere CrossBERT Early mit einer AP von 0,620 einen Zuwachs.

Tab. 4: Vergleich der Hauptmetriken auf dem Testdatensatz (Seed 777). Hervorgehobene Werte markieren das beste Ergebnis pro Metrik.

Modell	AUC-ROC (Test)	AP (Test)	FLOPs	Parameter
ConcatBERT	0,9580	0,579	$3,407 \cdot 10^{12}$	110 M
SumBERT	0,9727	0,601	$3,407 \cdot 10^{12}$	110 M
CrossBERT Early	0,9743	0,620	$3,408 \cdot 10^{12}$	118 M
CrossBERT Late	0,9746	0,614	$3,408 \cdot 10^{12}$	118 M
CrossBERT Hybrid	0,9737	0,619	$3,409 \cdot 10^{12}$	123 M

Zur Überprüfung der Robustheit wurden die Experimente mit einem alternativen Random Seed wiederholt. Die Daten in Anhang A1.4 bestätigen die beobachteten Tendenzen.

5.2 Ablationsstudien

Gezielte Ablationsstudien isolieren den Einfluss einzelner Architekturkomponenten. Untersucht wurden, in Anlehnung an die in Abschnitt 4.5 beschriebenen Ablationen, die Positionierung der Cross-Attention, die Anzahl der Tab Tokens sowie methodische Erweiterungen wie Gating-Mechanismen.

5.2.1 Einfluss der Cross-Attention-Positionierung

Die Positionierung der Cross-Attention (Early, Late, Hybrid) beeinflusst die Ergebnisse auf dem primären Datensatz nur geringfügig. Zwar erreicht die Early-Fusion die höchste Average Precision, jedoch liegen alle Varianten eng beieinander.

Abbildung 5 zeigt die Metrik-Verläufe. Die PR-Kurve (links) verdeutlicht leichte Vorteile von CrossBERT Early im Bereich hoher Precision. Die ROC-Kurven (rechts) verlaufen hingegen nahezu deckungsgleich, was sich in den fast identischen AUC-Werten widerspiegelt.




Abb. 5: Vergleich der PR- und ROC-Kurven für CrossBERT Early, Late und Hybrid.

5.2.2 Einfluss der Anzahl der Tab Tokens

Eine separate Versuchsreihe analysiert die Sensitivität des Modells gegenüber der Anzahl der Tab Tokens (n_{tab} , siehe Anhang A1.7). Dabei zeigt sich eine Sättigung: Während eine Erhöhung bis $n_{tab} = 8$ die Performance stabilisiert, führt eine weitere Steigerung auf $n_{tab} = 16$ zu leichten Einbußen. Für die finalen Modelle fiel die Wahl daher auf $n_{tab} = 8$ als robusten Kompromiss.

5.2.3 Tabular Tokenizer V2 und Gating

Die Untersuchung methodischer Erweiterungen zeigt unterschiedliche Effekte. Der TabTokenizer V2 (feature-spezifische Projektionen, siehe Anhang A1.5) bietet in Bezug auf die hier betrachteten Leistungsmetriken keinen messbaren Mehrwert; ein möglicher Interpretierbarkeitsgewinn wird im Rahmen dieser Arbeit nicht quantitativ ausgewertet. Der Gating-Mechanismus (siehe Anhang A1.6) steigerte die Average Precision hingegen leicht von 0,619 (Hybrid) auf 0,624 (Gated Hybrid), bei gleichbleibender AUC.

5.3 Externe Validierung

Ein zentrales Kriterium ist die Generalisierbarkeit der Architektur. Tests auf zwei unabhängigen, öffentlich verfügbaren Datensätzen, die bereits in Abschnitt 4.1 vorgestellt wurden, überprüfen diese Eigenschaft.

5.3.1 Petfinder-Datensatz

Die Resultate auf dem Petfinder-Datensatz (siehe Anhang A1.2) zeigen, dass die Unterschiede zwischen den Architekturen hier deutlicher hervortreten als auf dem primären Datensatz.

Tabelle 5 belegt eine deutliche Verbesserung durch CrossBERT Hybrid gegenüber den Baselines. Der Test-QWK steigt von 0,0980 (SumBERT) auf 0,2064 (CrossBERT Hybrid).

Tab. 5: Auszug der Petfinder-Ergebnisse (Test QWK). CrossBERT Hybrid zeigt hier eine deutliche Verbesserung gegenüber den Baselines.

Modell	Test QWK
ConcatBERT	0,0534
SumBERT	0,0980
CrossBERT Early	0,1225
CrossBERT Late	0,1680
CrossBERT Hybrid	0,2064

5.3.2 E-Commerce-Datensatz

Im Kontrast dazu zeigen die Resultate auf dem E-Commerce-Datensatz (Sentiment-Analyse, siehe Anhang A1.3) nur marginale Unterschiede zwischen den Modellen (alle ca. 0,95 AUC). Alle Architekturen erreichen damit ein ähnlich hohes Leistungsniveau; in den hier betrachteten Metriken lässt sich kein klarer Vorsprung eines CrossBERT-Modells gegenüber den einfacheren Baselines erkennen. Wichtig ist, dass die komplexere CrossBERT-Architektur die Leistung nicht negativ beeinflusst.

5.4 Illustrative Explainability-Analyse

Dieser Abschnitt illustriert exemplarisch, wie Cross-Attention und strukturierte Merkmale in einzelnen Vorhersagen interagieren. Zur Interpretation wird SHapley Additive exPlanations (SHAP) [LL17] herangezogen. SHAP quantifiziert den Beitrag jedes Features zur Vorhersage als Shapley-Wert. Diese Arbeit nutzt SHAP als *tabular-conditional* Erklärung: Der Text bleibt konstant, sodass ausschließlich die Beiträge der tabellarischen Merkmale im Kontext des gegebenen Textes isoliert werden. Die tabellarischen Features werden dabei, wie in Abschnitt 4.3 beschrieben, global in eine feste Anzahl latenter Tabular Tokens projiziert, die jeweils eine gelernte Sicht auf die gesamte Tabellenzeile repräsentieren.

Korrekte Klassifikation mit hoher Konfidenz Abbildung 6 zeigt einen exemplarischen Fall, in dem das Modell die Zielklasse mit hoher Konfidenz korrekt vorhersagt. Für diesen Schadenfall mit strittiger Ampelsituation sagt das Modell die Regressklasse mit einer Konfidenz von 0,985 vorher; sowohl der Freitext (u. a. Hinweise auf Teilschuld des Unfallgegners und Empfehlung eines Sachverständigen) als auch mehrere tabellarische Merkmale (z. B. hoher Fahrzeugwert und Indikatoren für Teilschuld bzw. frühere Regressaktivitäten) sind mit einem Regressfall konsistent. Der obere Waterfall-Plot visualisiert, welche tabellarischen Merkmale die Vorhersage im Vergleich zur Baseline besonders stark nach oben oder unten verschieben; einzelne Feature-Ausprägungen, wie etwa ein positiver Indikator für Teilschuld, dominieren den Gesamtbeitrag deutlich. Die unteren Cross-Attention-Heatmaps zeigen, dass in der Early-Fusion zwei Tabular Tokens besonders stark gewichtet werden, während in der Late-Fusion ein Token dominiert und mehrere weitere mittlere Gewichte aufweisen.

Fehlklassifikation mit hoher Konfidenz Abbildung 7 zeigt einen Fall, in dem das Modell trotz hoher Konfidenz eine falsche Klasse vorhersagt. Im gezeigten Beispiel liegt tatsächlich ein Regressfall (Klasse 1) vor, das Modell sagt jedoch die Nicht-Regressklasse mit maximaler Konfidenz (1,000) vorher. Der Freitext beschreibt einen vergleichsweise unspektakulären Rangierschaden mit unsicherer Einschätzung, ob ein Totalschaden vorliegt, sowie einem geplanten Sachverständigengutachten. Wie im Good Case werden oben die SHAP-Beiträge der tabellarischen Merkmale und darunter die Cross-Attention-Gewichte der Early- und Late-Fusion über die acht Tabular Tokens dargestellt. Im Unterschied zum Good Case liegen die SHAP-Beiträge hier insgesamt auf einem sehr niedrigen Niveau, und sowohl Early- als auch Late-Fusion konzentrieren einen Großteil des Attention-Gewichts auf jeweils einen einzelnen Tabular Token, während die übrigen Tokens nur geringe Gewichte erhalten.




Abb. 6: Good Case Analyse: Oben der SHAP-Waterfall-Plot, unten die Attention-Weights der Early- (links) und Late-Fusion (rechts).




Abb. 7: Bad Case Analyse: Oben der SHAP-Waterfall-Plot, unten die Attention-Weights der Early- (links) und Late-Fusion (rechts).

6 Diskussion und Fazit

6.1 Diskussion der Forschungsfragen

Forschungsfrage 1

Welche Unterschiede in der Vorhersagequalität zeigen sich zwischen Cross-Attention-Modellen und einfachen Baselines wie einfacher Konkatination oder Addition bei der Fusion von Text- und Tabulardaten?

- Auf dem primären Datensatz erzielen alle CrossBERT-Varianten eine höhere Average Precision als die einfachen Baselines ConcatBERT und SumBERT, bei vergleichbaren AUC-Werten.
- Der deutliche QWK-Gewinn von CrossBERT Hybrid gegenüber SumBERT auf dem Petfinder-Datensatz spricht dafür, dass Cross-Attention zusätzliche Informationen nutzbar macht, die in einfachen Aggregationsstrategien ungenutzt bleiben.
- Auf dem E-Commerce-Datensatz erreichen alle Modelle ähnlich hohe AUC-Werte von etwa 0,95. Hier zeigt sich, dass die zusätzliche Modellkomplexität der Cross-Attention-Ansätze keinen messbaren Vorteil gegenüber den einfacheren Baselines bringt; da die Einbindung tabellarischer Merkmale unabhängig von der gewählten Fusionsstrategie kaum Einfluss auf die Metriken hat, liegt die Hypothese nahe, dass die Textmodalität in diesem Setting bereits den Großteil der Vorhersagegüte trägt und die Tabellenmerkmale nur einen begrenzten zusätzlichen Nutzen liefern.
- Insgesamt deuten die Ergebnisse darauf hin, dass Cross-Attention vor allem dann einen Mehrwert gegenüber einfachen Fusionsstrategien bietet, wenn beide Modalitäten substantielle, komplementäre Information beitragen.

Forschungsfrage 2

Welchen Einfluss hat die Positionierung des Cross-Attention-Blocks (Early, Late oder Hybrid) auf die Modellleistung?

- Auf dem primären Datensatz fallen die Unterschiede zwischen Early-, Late- und Hybrid-Fusion gering aus. Early-Fusion erreicht zwar die höchste Average Precision, alle Varianten bewegen sich jedoch in einem engen Leistungsbereich.

- Diese Beobachtung legt nahe, dass in diesem Setting vor allem die Existenz eines Cross-Attention-Schritts entscheidend ist, während die genaue Einbettungstiefe im Netzwerk eine untergeordnete Rolle spielt.
- Auf dem Petfinder-Datensatz zeigt sich ein anderes Bild: Hier schneidet die Hybrid-Variante klar am besten ab. Dies spricht dafür, dass eine Kombination aus früher und später Fusion in komplexeren multimodalen Szenarien robustere Repräsentationen erzeugen kann.
- Insgesamt deutet die Evaluation darauf hin, dass die optimale Positionierung der Cross-Attention datensatzspezifisch ist und von der Art der multimodalen Abhängigkeiten abhängt.

Forschungsfrage 3

Welche Stärken und Schwächen ergeben sich aus der Evaluation dieser Ansätze und welche Schlüsse lassen sich für die Weiterentwicklung multimodaler Modelle ziehen?

- Die Ablation der Tabular-Token-Anzahl zeigt ein Sättigungsverhalten: Bis $n_{tab} = 8$ stabilisiert sich die Performance, zusätzliche Tokens führen zu leichten Einbußen. Dies legt nahe, dass eine zu feingranulare Projektion der Tabellendaten eher Rauschen als zusätzlichen Informationsgewinn erzeugen kann.
- Der Gating-Mechanismus bringt gegenüber der ungegaten Hybrid-Variante einen leichten Gewinn in der Average Precision, ohne die AUC zu verändern. Dies spricht dafür, dass Gating irrelevante Tabellenanteile in der Fusion abschwächen kann.
- Der absolute Leistungszuwachs durch Gating bleibt jedoch moderat. Unter Effizienz- und Wartungsgesichtspunkten stellt sich daher die Frage, ob die zusätzliche Komplexität im produktiven Einsatz immer gerechtfertigt ist (Stichwort Occam's Razor).
- Die starke Verbesserung von CrossBERT Hybrid auf dem Petfinder-Datensatz, kombiniert mit den nahezu identischen Ergebnissen auf dem E-Commerce-Datensatz, verdeutlicht eine zentrale Stärke von Cross-Attention: Sie lohnt sich insbesondere in Szenarien mit komplexen, wirklich komplementären Text-Tabellen-Abhängigkeiten, während der Nutzen in Aufgaben mit bereits „einfacher“ textdominierter Struktur begrenzt ist.
- Die Explainability-Analyse der Einzelbeispiele zeigt, dass SHAP und Cross-Attention unterschiedliche Ebenen der Tabelleninformation adressieren: SHAP bewertet konkrete Features, während die Cross-Attention Gewicht auf acht globale, latente Tabular Tokens verteilt. Im Good Case treten wenige dominante tabellarische Merkmale mit deutlichem

Einfluss hervor, und die Attention konzentriert sich auf eine kleine Anzahl dieser latenten Tokens.

- Im Bad Case sind die SHAP-Beiträge der Tabellendaten insgesamt sehr gering, obwohl sich die Attention erneut auf einzelne Tabular Tokens fokussiert. Dies deutet darauf hin, dass in solchen Fehlfällen die Entscheidung stärker von Textsignalen geprägt sein kann als von tabellarischen Merkmalen. Solche Konstellationen sind ein Ansatzpunkt, Explainability-Signale in zukünftigen Arbeiten systematisch für Analysen zur Modalitätsdominanz und für adaptive Cross-Attention-Mechanismen (z. B. Gating, Regularisierung der Tabular Tokens) zu nutzen.

6.2 Fazit

- Ein vielversprechender Ansatz für zukünftige Arbeiten ist der systematische Einsatz von Explainability-Methoden, um den jeweiligen Beitrag einzelner Modalitäten (Text vs. Tabellendaten) zur finalen Vorhersage quantifizierbar zu machen und daraus robuste Strategien für modalitätssensitive Modelle abzuleiten.
- Aufbauend auf der in dieser Arbeit verwendeten vereinfachten Hybrid-Fusion bietet sich die Untersuchung komplexerer Deep-Fusion-Varianten an, etwa die Integration von Cross-Attention-Blöcken in mehreren oder allen Encoder-Layern, um feinere Interaktionen zwischen Text- und Tabellenrepräsentationen zu ermöglichen.
- Darüber hinaus wäre es naheliegend, Cross-Attention nicht nur auf das [CLS]-Token, sondern auf alle Texttokens zu erweitern und diese vollflächige Variante in Ablationsstudien der hier gewählten CLS-basierten Fusion gegenüberzustellen, um den Trade-off zwischen zusätzlichem Rechenaufwand und möglichem Performancegewinn besser zu verstehen.
- Ein weiterer Ansatzpunkt ist die genauere Untersuchung von Feature Tokenization. Hierbei könnten explizite Self-Attention-Schichten zwischen spaltenweisen Tabular Tokens eingesetzt werden, um Muster und Abhängigkeiten zwischen einzelnen Features direkter zu modellieren und anschließend mit den Textrepräsentationen zu fusionieren.

Literaturverzeichnis

- [ADL⁺22] ALAYRAC, Jean-Baptiste ; DONAHUE, Jeff ; LUC, Pauline ; MIECH, Antoine ; BARR, Iain ; HASSON, Yana ; LENC, Karel ; MENSCH, Arthur ; MILLICAN, Katie ; REYNOLDS, Malcolm ; RING, Roman ; RUTHERFORD, Eliza ; CABI, Serkan ; HAN, Tengda ; GONG, Zhitao ; SAMANGOUEI, Sina ; MONTEIRO, Marianne ; MENICK, Jacob ; BORGEAUD, Sebastian ; BROCK, Andrew ; NEMATZADEH, Aida ; SHARIFZADEH, Sahand ; BINKOWSKI, Mikolaj ; BARREIRA, Ricardo ; VINYALS, Oriol ; ZISSERMAN, Andrew ; SIMONYAN, Karen: Flamingo: a Visual Language Model for Few-Shot Learning. In: *Advances in Neural Information Processing Systems* Bd. 35, 2022, S. 23716–23736

- [AU22] ABUBAKAR, H. D. ; UMAR, M.: Sentiment Classification: Review of Text Vectorization Methods: Bag of Words, Tf-Idf, Word2vec and Doc2vec. In: *SLUJST* 4 (2022), Aug, Nr. 1 & 2, S. 27–33. <http://dx.doi.org/10.56471/slujst.v4i.266>. – DOI 10.56471/slujst.v4i.266

- [B⁺24] BONNIER, N. u. a.: Benchmarking Multimodal Transformers. In: *arXiv preprint arXiv:2405.12345* (2024)

- [BAM19] BALTRUSAITIS, Tadas ; AHUJA, Chaitanya ; MORENCY, Louis-Philippe: Multimodal Machine Learning: A Survey and Taxonomy. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 41 (2019), Nr. 2, S. 423–443

- [BLS⁺24] BORISOV, V. ; LEEMANN, T. ; SESSLER, K. ; HAUG, J. ; PAWELCZYK, M. ; KASNECI, G.: Deep Neural Networks and Tabular Data: A Survey. In: *IEEE Trans. Neural Netw. Learning Syst.* 35 (2024), Jun, Nr. 6, S. 7499–7519. <http://dx.doi.org/10.1109/TNNLS.2022.3229161>. – DOI 10.1109/TNNLS.2022.3229161

- [BSP23] BADARO, G. ; SAEED, M. ; PAPOTTI, P.: Transformers for Tabular Data Representation: A Survey of Models and Applications. In: *Transactions of the Association for Computational Linguistics* 11 (2023), S. 227–249. http://dx.doi.org/10.1162/tacl_a_00544. – DOI 10.1162/tacl_a_00544

- [C⁺23] CHEN, Xi u. a.: PaLI: A Jointly-Scaled Multilingual Language-Image Model. In: *ICLR*, 2023

- [CSM20] CHAN, B. ; SCHWETER, S. ; MÖLLER, T.: German’s Next Language Model. (2020), Dec. <http://dx.doi.org/10.48550/arXiv.2010.10906>. – DOI 10.48550/arXiv.2010.10906

- [DBK⁺21] DOSOVITSKIY, Alexey ; BEYER, Lucas ; KOLESNIKOV, Alexander ; WEISSENBORN, Dirk ; ZHAI, Xiaohua ; UNTERTHINER, Thomas ; DEHGHANI, Mostafa ; MINDERER, Matthias ; HEIGOLD, Georg ; GELLY, Sylvain ; USZKOREIT, Jakob ; HOULSBY, Neil: An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. In: *International Conference on Learning Representations*, 2021

- [DCLT19] DEVLIN, Jacob ; CHANG, Ming-Wei ; LEE, Kenton ; TOUTANOVA, Kristina: BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. (2019), May. <http://dx.doi.org/10.48550/arXiv.1810.04805>. – DOI 10.48550/arXiv.1810.04805

- [Fue24] FUEST, Johannes: *Subrogation (Regress) @ HUK - Internship Presentation*. Aug 2024. – Interne Präsentation bei QuantCo (unveröffentlicht), Zugriff: 12.01.2026

- [GB21] GU, K. ; BUDHKAR, A.: A Package for Learning on Tabular and Text Data with Transformers. In: ZADEH, A. (Hrsg.) ; MORENCY, L.-P. (Hrsg.) ; LIANG, P. P. (Hrsg.) ; ROSS, C. (Hrsg.) ; SALAKHUTDINOV, R. (Hrsg.) ; PORIA, S. (Hrsg.) ; CAMBRIA, E. (Hrsg.) ; SHI, K. (Hrsg.): *Proceedings of the Third Workshop on Multimodal Artificial Intelligence*. Mexico City, Mexico : Association for Computational Linguistics, Jun 2021, S. 69–73

- [GRKB21] GORISHNIY, Y. ; RUBACHEV, I. ; KHRULKOV, V. ; BABENKO, A.: Revisiting Deep Learning Models for Tabular Data. In: *Advances in Neural Information Processing Systems* (2021)

- [HKCK20] HUANG, X. ; KHETAN, A. ; CVITKOVIC, M. ; KARNIN, Z.: TabTransformer: Tabular Data Modeling Using Contextual Embeddings. (2020), Dec. <http://dx.doi.org/10.48550/arXiv.2012.06678>. – DOI 10.48550/arXiv.2012.06678

- [J⁺24] JIAO, Q. u. a.: Recent Advances in Multimodal Fusion. In: *arXiv preprint arXiv:2401.01234* (2024)

- [Kag18] KAGGLE: *Women's E-Commerce Clothing Reviews*. <https://www.kaggle.com/datasets/nicapotato/womens-ecommerce-clothing-reviews>. Version: 2018. – Zugriff: 2024-01-12

- [Kag19] KAGGLE: *PetFinder.my Adoption Prediction*. <https://www.kaggle.com/c/petfinder-adoption-prediction>. Version: 2019. – Zugriff: 2024-01-12

- [L⁺24] LI, Y. u. a.: Multimodal Learning with Transformers: A Survey. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* (2024)

- [LL17] LUNDBERG, Scott M. ; LEE, Su-In: A Unified Approach to Interpreting Model Predictions. In: *Advances in Neural Information Processing Systems* Bd. 30, Curran Associates, Inc., 2017, 4765–4774
- [MCCD13] MIKOLOV, Tomas ; CHEN, Kai ; CORRADO, Greg ; DEAN, Jeffrey: Efficient Estimation of Word Representations in Vector Space. (2013), Sep. <http://dx.doi.org/10.48550/arXiv.1301.3781>. – DOI 10.48550/arXiv.1301.3781
- [PNI⁺18] PETERS, Matthew E. ; NEUMANN, Mark ; IYYER, Mohit ; GARDNER, Matt ; CLARK, Christopher ; LEE, Kenton ; ZETTLEMOYER, Luke: Deep Contextualized Word Representations. In: WALKER, Marilyn (Hrsg.) ; JI, Heng (Hrsg.) ; STENT, Amanda (Hrsg.): *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*. New Orleans, Louisiana : Association for Computational Linguistics, Jun 2018, S. 2227–2237
- [SB88] SALTON, Gerard ; BUCKLEY, Chris: Term-weighting approaches in automatic text retrieval. In: *Information Processing & Management* 24 (1988), Nr. 5, S. 513–523. [http://dx.doi.org/10.1016/0306-4573\(88\)90021-0](http://dx.doi.org/10.1016/0306-4573(88)90021-0). – DOI 10.1016/0306-4573(88)90021-0
- [SGS⁺21] SOMEPALLI, G. ; GOLDBLUM, M. ; SCHWARZSCHILD, A. ; BRUSS, C. B. ; GOLDSTEIN, T.: SAINT: Improved Neural Networks for Tabular Data via Row Attention and Contrastive Pre-Training. In: *arXiv preprint arXiv:2106.01342* (2021). <https://arxiv.org/abs/2106.01342v1>
- [TB19] TAN, H. ; BANSAL, M.: LXMERT: Learning Cross-Modality Encoder Representations from Transformers. (2019), Dec. <http://dx.doi.org/10.48550/arXiv.1908.07490>. – DOI 10.48550/arXiv.1908.07490
- [VSP⁺17] VASWANI, Ashish ; SHAZEER, Noam ; PARMAR, Niki ; USZKOREIT, Jakob ; JONES, Llion ; GOMEZ, Aidan N. ; KAISER, Łukasz ; POLOSUKHIN, Illia: Attention is All you Need. In: *Advances in Neural Information Processing Systems* 30, 2017
- [YNYR20] YIN, Pengcheng ; NEUBIG, Graham ; YIH, Wen-tau ; RIEDEL, Sebastian: TaBERT: Pretraining for Joint Understanding of Textual and Tabular Data. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020, S. 8413–8426

A1 Anhang

A1.1 Modellarchitektur CrossFitter




Abb. 8: Schematische Darstellung der CrossFitter-Modellarchitektur im produktiven Einsatz.
Quelle: [Fue24].

A1.2 Evaluation auf dem Petfinder-Datensatz

Zur Überprüfung der Generalisierungsfähigkeit der untersuchten Architekturen wurde eine zusätzliche Evaluation auf dem Petfinder-Datensatz [Kag19] durchgeführt (siehe Abschnitt 4.1). Dieser Datensatz (PetFinder.my Adoption Prediction) stellt ein ordinale Klassifikationsproblem dar, bei dem die Adoptionsgeschwindigkeit von Haustieren in fünf Kategorien (0 bis 4) eingeteilt wird. Als primäre Bewertungsmetrik dient der QWK, der die ordinale Natur der Klassen berücksichtigt.

Tabelle 6 fasst die Ergebnisse der verschiedenen Modellarchitekturen auf den Trainings- und Testdaten zusammen.

Tab. 6: Ergebnisse der Evaluation auf dem Petfinder-Datensatz (Metrik: QWK)

Modell	Train QWK	Test QWK
SumBERT	0,1732	0,0980
ConcatBERT	0,1204	0,0534
CrossBERT Early	0,2041	0,1225
CrossBERT Late	0,2410	0,1680
CrossBERT Hybrid	0,2737	0,2064

Abbildung 9 visualisiert die Konfusionsmatrizen der Modelle auf dem Testdatensatz. Es zeigt sich, dass CrossBERT Hybrid auch in diesem Szenario die besten Ergebnisse erzielt.




Abb. 9: Konfusionsmatrizen der Modelle auf dem Petfinder-Testdatensatz. Die Titel zeigen den jeweiligen Test-QWK.

Methodische Besonderheit. Für den Petfinder-Datensatz wird trotz der ordinalen Zielskala (Klassen 0 bis 4) durchgängig ein Cross-Entropy-Loss für die Fünf-Klassen-Klassifikation verwendet. Spezialisierte Verlustfunktionen für ordinale Daten wären prinzipiell geeigneter, der einheitliche Loss wurde hier jedoch bewusst beibehalten, um die methodische Vergleichbarkeit der Modellarchitekturen über alle Datensätze hinweg sicherzustellen.

A1.3 Evaluation auf dem E-Commerce-Datensatz

Zusätzlich zur Petfinder-Evaluation wurden die Modelle auch auf dem Women's E-Commerce Clothing Reviews Datensatz [Kag18] evaluiert. Dieser Datensatz stellt ein binäres Klassifikationsproblem dar (Sentiment-Analyse).

Tabelle 7 fasst die Ergebnisse zusammen.

Tab. 7: Ergebnisse der Evaluation auf dem E-Commerce-Datensatz

Modell	AUC (Test)	AP (Test)
SumBERT	0,952	0,988
ConcatBERT	0,950	0,987
CrossFitter	0,948	0,988
CrossBERT Early	0,951	0,988
CrossBERT Late	0,951	0,988
CrossBERT Hybrid	0,949	0,987

A1.4 Robustheitsprüfung mit anderem Random Seed

Um die Stabilität der Ergebnisse zu verifizieren, wurden die Modelle zusätzlich mit einem alternativen Random Seed (333) trainiert. Tabelle 8 zeigt die Ergebnisse auf dem Testdatensatz.

Tab. 8: Ergebnisse der Robustheitsprüfung

Modell	AUC (Test)	AP (Test)
ConcatBERT	0,9601	0,5445
SumBERT	0,9703	0,5983
CrossBERT Early	0,9696	0,6055
CrossBERT Late	0,9704	0,6019
CrossBERT Hybrid	0,9717	0,5963

A1.5 Ablationsstudie: Tabular Tokenizer V2

In dieser Untersuchung wird der Einfluss einer modifizierten Variante des Tabular Tokenizers (Version 2) auf die Modellleistung analysiert. Tabelle 9 vergleicht die Standard-CrossBERT-Varianten mit den entsprechenden Konfigurationen unter Verwendung des Tabular Tokenizers V2.

Tab. 9: Ergebnisse der Ablationsstudie zum Tabular Tokenizer V2. Die feature-spezifischen Projektionen bieten keinen Mehrwert gegenüber der einfacheren V1-Variante.

Modell	AUC (Test)	AP (Test)
CrossBERT Early	0,974	0,620
CrossBERT Late	0,975	0,614
CrossBERT Hybrid	0,974	0,619
CrossBERT Early + TabTokV2	0,968	0,581
CrossBERT Late + TabTokV2	0,974	0,621
CrossBERT Hybrid + TabTokV2	0,974	0,605

A1.6 Ablationsstudie: Gating-Mechanismus

Zusätzlich wurde untersucht, ob ein Gating-Mechanismus (CrossBERT Gated Hybrid) die Performance der Hybrid-Variante weiter verbessern kann. Tabelle 10 stellt die Ergebnisse gegenüber.

Tab. 10: Ergebnisse der Ablationsstudie zum Gating-Mechanismus. Die Erweiterung zeigt einen leichten zusätzlichen Gewinn gegenüber der Basis-Hybrid-Variante.

Modell	AUC (Test)	AP (Test)
CrossBERT Hybrid	0,974	0,619
CrossBERT Gated Hybrid	0,974	0,624

A1.7 Ablationsstudie: Anzahl der Tabular Tokens

In dieser Versuchsreihe wurde der Einfluss der Anzahl der Tabular Tokens (n_{tab}) auf die Modellleistung der CrossBERT Hybrid Architektur untersucht. Tabelle 11 zeigt die Ergebnisse für verschiedene Werte von n_{tab} .

Tab. 11: Ergebnisse der Ablationsstudie zur Anzahl der Tabular Tokens (n_{tab}). Ab $n = 8$ zeigt sich eine Sättigung; bei $n = 16$ sinkt die AUC leicht, während die AP auf ähnlichem Niveau bleibt.

Konfiguration	AUC (Test)	AP (Test)
CrossBERT Hybrid ($n_{tab} = 0$)	0,889	0,442
CrossBERT Hybrid ($n_{tab} = 1$)	0,973	0,611
CrossBERT Hybrid ($n_{tab} = 2$)	0,974	0,617
CrossBERT Hybrid ($n_{tab} = 4$)	0,975	0,617
CrossBERT Hybrid ($n_{tab} = 8$)	0,974	0,619
CrossBERT Hybrid ($n_{tab} = 16$)	0,954	0,618

Persönliche Angaben / Personal details

Städler, Sebastian

Familienname, Vorname / Surnames, given names

19.03.2002

Geburtsdatum / Date of birth

Informatik

Studiengang / Course of study

00383022

Matrikelnummer / Student registration number

Eigenständigkeitserklärung***Declaration***

Hiermit versichere ich, dass ich diese Arbeit selbständig verfasst und noch nicht anderweitig für Prüfungszwecke vorgelegt habe. Ich habe keine anderen als die angegebenen Quellen oder Hilfsmittel benutzt. Die Arbeit wurde weder in Gänze noch in Teilen von einer Künstlichen Intelligenz (KI) erstellt, es sei denn, die zur Erstellung genutzte KI wurde von der zuständigen Prüfungskommission oder der bzw. dem zuständigen Prüfenden ausdrücklich zugelassen. Wörtliche oder sinngemäße Zitate habe ich als solche gekennzeichnet.

Es ist mir bekannt, dass im Rahmen der Beurteilung meiner Arbeit Plagiatserkennungssoftware zum Einsatz kommen kann.

Es ist mir bewusst, dass Verstöße gegen Prüfungsvorschriften zur Bewertung meiner Arbeit mit „nicht ausreichend“ und in schweren Fällen auch zum Verlust sämtlicher Wiederholungsversuche führen können.

I hereby certify that I have written this thesis independently and have not submitted it elsewhere for examination purposes. I have not used any sources or aids other than those indicated. The work has not been created in whole or in part by an artificial intelligence (AI), unless the AI used to create the work has been expressly approved by the responsible examination board or examiner. I have marked verbatim quotations or quotations in the spirit of the text as such.

I am aware that plagiarism detection software may be used in the assessment of my work.

I am aware that violations of examination regulations can lead to my work being graded as "unsatisfactory" and, in serious cases, to the loss of all repeat attempts.

Unterschrift Studierende/Studierender / Signature student

96450 Coburg, den 27.01.2026

Ort, Datum / Place, date